

# Resolución numérica del problema no lineal de mínimos cuadrados. Aplicaciones a las estimación de parámetros de modelos matemáticos.

Dídac Blanco Morros

14 de febrero de 2023



FACULDADE DE MATEMÁTICAS

# Índice.

Fundamentos de la optimización sin restricciones

Mínimos Cuadrados

El método de Levenberg-Marquardt

Implementación en Matlab<sup>®</sup>

# Índice.

Fundamentos de la optimización sin restricciones

Mínimos Cuadrados

El método de Levenberg-Marquardt

Implementación en Matlab®

# Conceptos previos

Un problema de optimización sin restricciones tiene la forma

$$\min_x f(x)$$

- $x \in \mathbb{R}^n$  y  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  es continuamente diferenciable.
- A  $f$  se le llama función objetivo.

# Conceptos previos

- Norma euclídea:  $\|x\|_2 = (\sum_{i=1}^n |x_i|^2)^{1/2}$ .
- Punto estacionario de  $f$ :  $\nabla f(x) = 0$ .
- Mínimo  $x^*$ : existe  $\delta > 0$  tal que  $f(x^*) \leq f(x)$ .
- Mínimo estricto  $x^*$ : existe  $\delta > 0$  tal que  $f(x^*) < f(x)$  con  $x \neq x^*$ .
  - Local: para todo  $x \in \mathbb{R}^n$  que satisface  $\|x - x^*\| < \delta$ .
  - Global: para todo  $x \in \mathbb{R}^n$
- Producto escalar de  $x$  e  $y$  en  $\mathbb{R}^n$ :  $\langle x, y \rangle = \sum_{i=1}^n x_i y_i$ .
- Dirección descendente de  $f$  en  $x$ :  $d \in \mathbb{R}^n$  tal que  $\langle \nabla f(x), d \rangle < 0$ .

# Condiciones de optimalidad

Consideremos el problema inicial

$$\min_x f(x)$$

# Condiciones de optimalidad

Consideremos el problema inicial

$$\min_x f(x)$$

## Teorema: Condición Necesaria de Primer Orden

Sea  $f : D \subset \mathbb{R}^n \rightarrow \mathbb{R}$  continuamente diferenciable en un conjunto abierto  $D$ . Si  $x^*$  es un mínimo local, entonces  $\nabla f(x^*) = 0$ .

# Condiciones de optimalidad

Consideremos el problema inicial

$$\min_x f(x)$$

## Teorema: Condición Necesaria de Primer Orden

Sea  $f : D \subset \mathbb{R}^n \rightarrow \mathbb{R}$  continuamente diferenciable en un conjunto abierto  $D$ . Si  $x^*$  es un mínimo local, entonces  $\nabla f(x^*) = 0$ .

## Teorema: Condición Necesaria de Segundo Orden

Sea  $f : D \subset \mathbb{R}^n \rightarrow \mathbb{R}$  dos veces continuamente diferenciable en un conjunto abierto  $D$ . Si  $x^*$  es un mínimo local, entonces  $\nabla f(x^*) = 0$  y  $\nabla^2 f(x^*)$  es definida positiva.



# Condiciones de optimalidad

Consideremos el problema inicial

$$\min_x f(x)$$

## Teorema: Condición Necesaria de Primer Orden

Sea  $f : D \subset \mathbb{R}^n \rightarrow \mathbb{R}$  continuamente diferenciable en un conjunto abierto  $D$ . Si  $x^*$  es un mínimo local, entonces  $\nabla f(x^*) = 0$ .

## Teorema: Condición Necesaria de Segundo Orden

Sea  $f : D \subset \mathbb{R}^n \rightarrow \mathbb{R}$  dos veces continuamente diferenciable en un conjunto abierto  $D$ . Si  $x^*$  es un mínimo local, entonces  $\nabla f(x^*) = 0$  y  $\nabla^2 f(x^*)$  es definida positiva.

## Teorema: Condición Suficiente de Segundo Orden

Sea  $f : D \subset \mathbb{R}^n \rightarrow \mathbb{R}$  dos veces continuamente diferenciable en un conjunto abierto  $D$ . Si  $\nabla f(x^*) = 0$  y  $\nabla^2 f(x^*)$  es definida positiva, entonces  $x^* \in D$  es un mínimo local.

# Algoritmos. ¿Qué son?

- Conjunto de órdenes con normas y condiciones.

# Algoritmos. ¿Qué son?

- Conjunto de órdenes con normas y condiciones.
- Estructura de bucles iterativos.

# Algoritmos. ¿Qué son?

- Conjunto de órdenes con normas y condiciones.
- Estructura de bucles iterativos.
- Eficiencia computacional.

# Algoritmos. ¿Qué son?

- Conjunto de órdenes con normas y condiciones.
- Estructura de bucles iterativos.
- Eficiencia computacional.
- Mínimos locales y globales.

# Algoritmos. Esquema.

Paso 1. Paso inicial. Se definen las condiciones iniciales, suelen ser el primer punto de la sucesión  $\{x_k\}$ , valores para definir las condiciones de parada como el número máximo de iteraciones o el error aceptable, y otros parámetros.

# Algoritmos. Esquema.

- Paso 1. Paso inicial. Se definen las condiciones iniciales, suelen ser el primer punto de la sucesión  $\{x_k\}$ , valores para definir las condiciones de parada como el número máximo de iteraciones o el error aceptable, y otros parámetros.
- Paso 2. Test de parada. Se comprueba si se cumple alguna condición de parada.

# Algoritmos. Esquema.

- Paso 1. Paso inicial. Se definen las condiciones iniciales, suelen ser el primer punto de la sucesión  $\{x_k\}$ , valores para definir las condiciones de parada como el número máximo de iteraciones o el error aceptable, y otros parámetros.
- Paso 2. Test de parada. Se comprueba si se cumple alguna condición de parada.
- Paso 3. Proceso principal. Se realizan los cálculos necesarios para avanzar de  $x_k$  a  $x_{k+1}$ .



# Algoritmos. Esquema.

- Paso 1. Paso inicial. Se definen las condiciones iniciales, suelen ser el primer punto de la sucesión  $\{x_k\}$ , valores para definir las condiciones de parada como el número máximo de iteraciones o el error aceptable, y otros parámetros.
- Paso 2. Test de parada. Se comprueba si se cumple alguna condición de parada.
- Paso 3. Proceso principal. Se realizan los cálculos necesarios para avanzar de  $x_k$  a  $x_{k+1}$ .
- Paso 4. Actualización y bucle. Se actualiza el valor de  $x_k$  a  $x_{k+1}$ , así como otros parámetros necesarios. Se repite el proceso desde el *paso 2*.

# Búsqueda de línea.

- Se toma el punto inicial  $x_k$  (para cada iteración).
- Elige una dirección  $d_k$  con la misma dimensión que  $x_k$ .
  - La mayoría eligen una dirección de descenso, esto es,  $d_k^T \nabla f_k < 0$ .
  - Suele tener la forma  $d_k = -B_k^{-1} \nabla f_k$ .
- Se elige una longitud de paso  $\alpha_k \in \mathbb{R}$ .
- Se obtiene  $x_{k+1} = x_k + \alpha_k d_k$ .
  - El objetivo es que  $f(x_{k+1}) < f(x_k)$ .
  - Si se se soluciona el problema  $\min_{\alpha_k} f(x_k + \alpha_k d_k)$ , búsqueda de línea exacta.

## Región de confianza.

- Se toma una pequeña región donde es más fácil predecir como se comporta la función.
- Primero se fija una distancia máxima  $\Delta_k$  para definir una región

$$\Omega_k = \{x : \|x - x_k\| \leq \Delta_k\}.$$

- Para predecir el comportamiento en esta región, se utilizan aproximaciones como la siguiente:

$$m_k(p) := q^{(k)}(p) = f(x_k) + g_k^T p + \frac{1}{2} p^T G_k p.$$

# Región de confianza.

## Subproblema de optimización con restricciones

$$\begin{array}{ll} \min_p & m_k(p) = f(x_k) + g_k^T p + \frac{1}{2} p^T B_k p \\ \text{s.a.} & \|p\| \leq \Delta_k, \end{array}$$

# Región de confianza.

## Subproblema de optimización con restricciones

$$\begin{aligned} \min_p \quad & m_k(p) = f(x_k) + g_k^T p + \frac{1}{2} p^T B_k p \\ \text{s.a.} \quad & \|p\| \leq \Delta_k, \end{aligned}$$

---

Jorge Nocedal y Stephen Wright. *Numerical Optimization*. 2.<sup>a</sup> ed. New York, NY: Springer, 2006

Wenyu Sun y Ya-Xiang Yuan. *Optimization theory and methods: Nonlinear programming*. 2006.<sup>a</sup> ed. New York, NY: Springer, 2006

# Región de confianza.

## Teorema: Caracterización de la solución del subproblema

El vector  $p^*$  es una solución global si y solo si  $p^*$  es factible y existe un escalar  $\lambda^* \geq 0$  tal que:

- $(B + \lambda^* I)p^* = -g$ ,
- $\lambda^*(\Delta - \|p^*\|) = 0$ ,
- $(B + \lambda^* I)$  es semidefinida positiva.

# Región de confianza.

## Ratio de aceptación

Para tener en cuenta la semejanza entre la aproximación y la función real, se define el ratio de aceptación:

$$\rho_k = \frac{f(x_k) - f(x_k + p_k)}{m_k(0) - m(p_k)},$$

el cual será más grande cuanto más parecida sea la aproximación a la función real. Se tiene en cuenta para la elección de  $\Delta_k$ .

## Región de confianza. Esquema.

Paso 1. Dados  $x_0, \bar{\Delta}, \Delta_0 \in (0, \bar{\Delta}), \epsilon \geq 0, 0 < \eta_1 \leq \eta_2 < 1$  y  $0 < \gamma_1 < 1 < \gamma_2, k := 0$ .

Paso 2. Si  $\|g_k\| \leq \epsilon$  terminar.

Paso 3. Aproximar  $p_k$  resolviendo según la caracterización.

Paso 4. Calcular  $f(x_k + p_k)$  y  $\rho_k$ . Definir

$$x_{k+1} = \begin{cases} x_k + p_k, & \text{si } \rho_k \geq \eta_1, \\ x_k, & \text{en otro caso.} \end{cases}$$

Paso 5. Si  $\rho_k < \eta_1$  entonces  $\Delta_{k+1} \in (0, \gamma_1 \Delta_k]$ .

Si  $\rho_k \in [\eta_1, \eta_2)$  entonces  $\Delta_{k+1} \in [\gamma_1 \Delta_k, \Delta_k]$ .

Si  $\rho_k \geq \eta_2$  y  $\|p_k\| = \Delta_k$  entonces

$\Delta_{k+1} \in [\Delta_k, \min\{\gamma_2 \Delta_k, \bar{\Delta}\}]$ .

Paso 6. Calcular  $B_{k+1}$ , actualizar  $m^{(k)}$  y  $k := k + 1$ . Ir al Paso 2.



# Índice.

Fundamentos de la optimización sin restricciones

Mínimos Cuadrados

El método de Levenberg-Marquardt

Implementación en Matlab®

## El problema.

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{2} \sum_{i=1}^m r_i^2(x), \quad m \geq n,$$

## El problema.

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{2} \sum_{i=1}^m r_i^2(x), \quad m \geq n,$$

- $x$  es el parámetro a estimar de dimensión  $n$ .

## El problema.

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{2} \sum_{i=1}^m r_i^2(x), \quad m \geq n,$$

- $x$  es el parámetro a estimar de dimensión  $n$ .
- $\phi_x(t)$  es la función a ajustar.

## El problema.

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{2} \sum_{i=1}^m r_i^2(x), \quad m \geq n,$$

- $x$  es el parámetro a estimar de dimensión  $n$ .
- $\phi_x(t)$  es la función a ajustar.
- $r_i(x) = \phi_x(t_i) - y_i$ ,  
para  $i = 1, \dots, m$  son los residuos.

# El problema.

$$\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{2} \sum_{i=1}^m r_i^2(x), \quad m \geq n,$$

- $x$  es el parámetro a estimar de dimensión  $n$ .
- $\phi_x(t)$  es la función a ajustar.
- $r_i(x) = \phi_x(t_i) - y_i$ , para  $i = 1, \dots, m$  son los residuos.






Figura: Ejemplo de ajuste de una recta a una muestra de puntos

## Ejemplo de ajuste de una recta a una muestra de puntos.



## Ejemplo de ajuste de una exponencial a una muestra de puntos.





# El método de Gauss-Newton.

# El método de Gauss-Newton.

- Se trata de una linealización del problema de mínimos cuadrados.

# El método de Gauss-Newton.

- Se trata de una linealización del problema de mínimos cuadrados.
- Para linealizar, se desprecia el término cuadrático de  $r_i(x)$  y se obtiene el caso lineal:

$$f(x) = \frac{1}{2} \|Jx - y\|^2.$$

$$\nabla f(x) = J^T (Jx - y), \quad \nabla^2 f(x) = J^T J.$$

# El método de Gauss-Newton.

- Se trata de una linealización del problema de mínimos cuadrados.
- Para linealizar, se desprecia el término cuadrático de  $r_i(x)$  y se obtiene el caso lineal:

$$f(x) = \frac{1}{2} \|Jx - y\|^2.$$

$$\nabla f(x) = J^T (Jx - y), \quad \nabla^2 f(x) = J^T J.$$

- Se resuelve el sistema lineal  $J^T Jx = J^T y$ .

# El método de Gauss-Newton.

- Se trata de una linealización del problema de mínimos cuadrados.
- Para linealizar, se desprecia el término cuadrático de  $r_i(x)$  y se obtiene el caso lineal:

$$f(x) = \frac{1}{2} \|Jx - y\|^2.$$

$$\nabla f(x) = J^T (Jx - y), \quad \nabla^2 f(x) = J^T J.$$

- Se resuelve el sistema lineal  $J^T Jx = J^T y$ .
- Convergencia local y cuadrática.

# El método de Gauss-Newton.

Paso 1. Dados  $x_0$  y  $\epsilon > 0$ ,  $k := 0$ .

Paso 2. Si  $\|g_k\| \leq \epsilon$ , terminar.

Paso 3. Obtener el paso  $p_k$  resolviendo

$$J(x_k)^T J(x_k) p_k = -J(x_k)^T r(x_k). \quad (1)$$

Paso 4. Definimos  $x_{k+1} = x_k + p_k$  y actualizamos  $k = k + 1$ . Ir a Paso 2.

# Índice.

Fundamentos de la optimización sin restricciones

Mínimos Cuadrados

El método de Levenberg-Marquardt

Implementación en Matlab®

# El método de Levenberg-Marquardt.

- Se mantiene la idea de la linealización de Gauss-Newton.



# El método de Levenberg-Marquardt.

- Se mantiene la idea de la linealización de Gauss-Newton.
- Se cambia de enfoque a región de confianza.

# El método de Levenberg-Marquardt.

- Se mantiene la idea de la linealización de Gauss-Newton.
- Se cambia de enfoque a región de confianza.

$$\begin{aligned} \min_p \quad & m_k(p) = \frac{1}{2} \|r_k\|^2 + p^T J_k^T r_k + \frac{1}{2} p^T J_k^T J_k p, \\ \text{s.a.} \quad & \|p\| \leq \Delta_k. \end{aligned}$$

# El método de Levenberg-Marquardt.

- Se mantiene la idea de la linealización de Gauss-Newton.
- Se cambia de enfoque a región de confianza.

$$\begin{aligned} \min_p \quad & m_k(p) = \frac{1}{2} \|r_k\|^2 + p^T J_k^T r_k + \frac{1}{2} p^T J_k^T J_k p, \\ \text{s.a.} \quad & \|p\| \leq \Delta_k. \end{aligned}$$

## Lema: Caracterización de la solución.

El vector  $p$  es solución del subproblema si y solo si  $p$  es factible y existe un  $\lambda \geq 0$  tal que

$$\begin{aligned} (J^T J + \lambda I)p &= -J^T r, \\ \lambda(\Delta - \|p\|) &= 0. \end{aligned}$$

# Propiedades del método de Levenberg-Marquardt.

- Convergencia global bajo ciertas condiciones.
- El ratio de convergencia es variable (ver Teorema 3.7).

---

Wenyu Sun y Ya-Xiang Yuan. *Optimization theory and methods: Nonlinear programming*. 2006.<sup>a</sup> ed. New York, NY: Springer, 2006

# Implementación del método de Levenberg-Marquardt.

## Versión de Moré

Disponemos de la implementación de este método propuesta por Jorge J. Moré, con un estudio detallado del mismo en su artículo<sup>1</sup>.

---

<sup>1</sup>Jorge J Moré. "The Levenberg-Marquardt algorithm: Implementation and theory". En: *Lecture Notes in Mathematics*. Berlin, Heidelberg: Springer Berlin Heidelberg, 1978, págs. 105-116.

# Implementación del método de Levenberg-Marquardt.

## Versión de Moré

Disponemos de la implementación de este método propuesta por Jorge J. Moré, con un estudio detallado del mismo en su artículo<sup>1</sup>.

Veremos a continuación en detalle:

- Actualización del radio  $\Delta_k$ .

---

<sup>1</sup>Jorge J Moré. "The Levenberg-Marquardt algorithm: Implementation and theory". En: *Lecture Notes in Mathematics*. Berlin, Heidelberg: Springer Berlin Heidelberg, 1978, págs. 105-116.

# Implementación del método de Levenberg-Marquardt.

## Versión de Moré

Disponemos de la implementación de este método propuesta por Jorge J. Moré, con un estudio detallado del mismo en su artículo<sup>1</sup>.

Veremos a continuación en detalle:

- Actualización del radio  $\Delta_k$ .
- El parámetro Levenberg-Marquardt.

---

<sup>1</sup>Jorge J Moré. "The Levenberg-Marquardt algorithm: Implementation and theory". En: *Lecture Notes in Mathematics*. Berlin, Heidelberg: Springer Berlin Heidelberg, 1978, págs. 105-116.

# Implementación del método de Levenberg-Marquardt.

## Versión de Moré

Disponemos de la implementación de este método propuesta por Jorge J. Moré, con un estudio detallado del mismo en su artículo<sup>1</sup>.

## Veremos a continuación en detalle:

- Actualización del radio  $\Delta_k$ .
- El parámetro Levenberg-Marquardt.
- Matriz de escalado  $D_k$ .

---

<sup>1</sup>Jorge J Moré. "The Levenberg-Marquardt algorithm: Implementation and theory". En: *Lecture Notes in Mathematics*. Berlin, Heidelberg: Springer Berlin Heidelberg, 1978, págs. 105-116.



# Implementación del método de Levenberg-Marquardt.

## Actualización del radio $\Delta_k$

En este caso particular el ratio viene dado por

$$\rho = \frac{\|r(x_k)\|^2 - \|r(x_k + p_k)\|^2}{\|r(x_k)\|^2 - \|r(x_k) + J(x_k)p_k\|^2},$$

y obtenemos la siguiente expresión explícita:

$$\rho = \frac{1 - \left[ \frac{\|r(x_k + p_k)\|}{\|r(x_k)\|} \right]^2}{\left[ \frac{\|J_k p\|}{\|r(x_k)\|} \right]^2 + 2 \left[ \frac{\lambda^{1/2} \|D_k p\|}{\|r(x_k)\|} \right]^2}.$$

# Implementación del método de Levenberg-Marquardt.

## El parámetro Levenberg-Marquardt

En esta implementación, se acepta  $\alpha > 0$  como parámetro de Levenberg-Marquardt Si

$$|\phi(\alpha)| \leq \sigma \Delta,$$

siendo

$$\phi(\alpha) = \left\| D(J^T J + \alpha D^T D)^{-1} J^T r \right\| - \Delta,$$

y  $\sigma \in (0, 1)$  es un parámetro que controla la aceptación de  $\alpha$ .

# Implementación del método de Levenberg-Marquardt.

Paso 1. Definir valores iniciales  $\alpha_0$ ,  $l_0$  y  $u_0$ . Definir coeficiente de parada  $\sigma$ .

Paso 2. Si  $\alpha_k \notin (l_k, u_k)$ , definir  $\alpha_k = \max\{0,001u_k, (l_k u_k)^{1/2}\}$ .

Paso 3. Calcular  $\phi(\alpha_k)$  y  $\phi'(\alpha_k)$ . Si  $|\phi(\alpha)| < \sigma\Delta$ , terminar.

Paso 4. Actualizar  $l_k$  y  $u_k$ :

$$l_{k+1} = \max\{l_k, \alpha_k - \frac{\phi(\alpha_k)}{\phi'(\alpha_k)}\},$$
$$u_{k+1} = \begin{cases} \alpha_k, & \text{si } \phi(\alpha_k) < 0, \\ u_k, & \text{en otro caso.} \end{cases}$$

Paso 5. Actualizar  $\alpha_{k+1}$  según

$$\alpha_{k+1} = \alpha_k - \left[ \frac{\phi(\alpha_k) + \Delta}{\Delta} \right] \left[ \frac{\phi(\alpha_k)}{\phi'(\alpha_k)} \right].$$

Volver al Paso 2.

# Implementación del método de Levenberg-Marquardt.

## Escalado

Para reducir posibles problemas de escalado, se utiliza una matriz diagonal  $D_k$  definido de la siguiente forma:

$$D_k = \text{diag}(d_1^{(k)}, \dots, d_n^{(k)}),$$

con

$$d_i^{(k)} = \|\partial_i r(x_k)\|, k \geq 0.$$

En cada paso, se actualiza cada  $d_i^{(k)}$  si este aumenta, es decir,

$$d_i^{(k)} = \max\{d_i^{(k-1)}, \|\partial_i r(x_k)\|\}, k \geq 1.$$

## Esquema del algoritmo. I.

- Paso 1. Definir valores iniciales  $x_0$ ,  $\Delta_0$  y  $\epsilon$  y determinar  $J_k$ ,  $D_k$ , y  $f(x_0)$  a partir de la función  $f$  determinada.
- Paso 2. Si  $\|J_k(D_k)^{-1}f(x_k)\| < \epsilon$ , terminar.
- Paso 3. Sea  $\sigma \in (0, 1)$ . Si  $\|D_k J_k^- r_k\| \leq (1 + \sigma)\Delta_k$ , asignar  $\lambda_k = 0$  y  $p_k = -J_k^- r_k$ . En otro caso, encontrar  $\lambda_k$  tal que si

$$\begin{bmatrix} J_k \\ \lambda_k^{\frac{1}{2}} D_k \end{bmatrix} p_k \cong - \begin{bmatrix} r_k \\ 0 \end{bmatrix},$$

entonces

$$(1 - \sigma)\Delta_k \leq \|D_k p_k\| \leq (1 + \sigma)\Delta_k.$$

- Paso 4. Determinar la relación  $\rho_k$  entre reducción real y la esperada.

## Esquema del algoritmo. II.

- Paso 5. Si  $\rho_k \leq 0,0001$ , asignar  $x_{k+1} = x_k$  y  $J_{k+1} = J_k$ .  
Si  $\rho_k > 0,0001$ , asignar  $x_{k+1} = x_k + p_k$  y calcular  $J_{k+1} = J(x_{k+1})$ .
- Paso 6. Si  $\rho_k \leq \frac{1}{4}$ , asignar  $\Delta_{k+1} \in [\frac{1}{10}\Delta_k, \frac{1}{4}\Delta_k]$ .  
Si  $\rho_k \in [\frac{1}{4}, \frac{3}{4}]$  y  $\lambda_k = 0$ , o si  $\rho_k \geq \frac{3}{4}$ , asignar  $\Delta_{k+1} = 2 \|D_k p_k\|$ .
- Paso 7. Actualizar  $D_k$  y volver al Paso 2.

# Índice.

Fundamentos de la optimización sin restricciones

Mínimos Cuadrados

El método de Levenberg-Marquardt

Implementación en Matlab<sup>®</sup>

# Inicialización.

Paso 1. Definir valores iniciales  $x_0$ ,  $\Delta_0$  y  $\epsilon$  y determinar  $J_k$ ,  $D_k$ , y  $f(x_0)$  a partir de la función  $f$  determinada.



# Inicialización.

Paso 1. Definir valores iniciales  $x_0$ ,  $\Delta_0$  y  $\epsilon$  y determinar  $J_k$ ,  $D_k$ , y  $f(x_0)$  a partir de la función  $f$  determinada.

```
1 function [xk, iter] = myLevMar(fun, x0)
2 % setup
3 [n,m,xk,Delta,funk,lambdak, maxit, maxit2,
   eps]= myLevMarSetup(fun,x0);
4
5 % calculo inicial de Jk y Dk
6 dkm1=zeros(length(xk));
7 [Jk, Dk, dkm1] = JDk(fun,xk,dkm1);
```

# Inicialización.

```
1 function [n,m,xk,Delta,funk,lambdak, maxit,
    maxit2, eps] = myLevMarSetup(fun,x0)
2 % editable
3 Delta = 3;
4 lambdak = 1;
5 maxit = 50;
6 maxit2 = 10; % miteraciones maximas en
    hebden.m
7 eps = 0.001;
8
9 % no editable
10 n = length(x0);
11 m = length(fun(x0));
12 xk = x0;
13 funk = fun(xk)';
```

# Inicialización.

```
1 function [Jk,Dk,v] = JDk(fun,xk,dkm1)
2
3 Jk = jacob(fun,xk);
4
5 % Compute diagonal of Dk
6 di = @(i) max(dkm1(i),norm(Jk(:,i))));
7
8 v = arrayfun(di, 1:length(xk));
9 Dk = diag(v);
```

# Inicialización.

```
1 function J = jacob(fun,xk)
2 h = 1e-5;
3 n = length(xk);
4 m = length(fun(xk));
5 J = zeros(m,n);
6 for j = 1:n
7     hj = zeros(1,n);
8     hj(j) = h;
9     J(:,j) = (fun(xk+hj)-fun(xk))./h;
10 end
```

## Test de parada.

Paso 2. Si  $\|J_k(D_k)^{-1}f(x_k)\| < \epsilon$ , terminar.

## Test de parada.

Paso 2. Si  $\|J_k(D_k)^{-1}f(x_k)\| < \epsilon$ , terminar.

```
1 try
2     test = norm((Jk*inv(Dk))'*funkt);
3 catch
4     test = norm((Jk*inv(Dk))'*funkt');
5 end
6 iter=0;
7 while test > eps && iter < maxit
```

## Bucle.

```
1 % solucion problema lineal
2 % descomposicion QR
3 [Q,R,Pi] = qr(Jk); % calcula  $J_k \cdot P_i = Q \cdot R$ 
4 % ajuste de R
5 T = R(1:n,1:n);
6 S = R(1:n,n+1:end);
7
8 % matriz  $J^{-}$ 
9 Jm = Jmfun(Pi,T,Q,n,m);
```

## Bucle.

Paso 3. Sea  $\sigma \in (0, 1)$ . Si  $\|D_k J_k^- r_k\| \leq (1 + \sigma)\Delta_k$ , asignar  $\lambda_k = 0$  y  $p_k = -J_k^- r_k$ . En otro caso, encontrar  $\lambda_k$  tal que si

$$\begin{bmatrix} J_k \\ \lambda_k^{\frac{1}{2}} D_k \end{bmatrix} p_k \cong - \begin{bmatrix} r_k \\ 0 \end{bmatrix},$$

entonces  $(1 - \sigma)\Delta_k \leq \|D_k p_k\| \leq (1 + \sigma)\Delta_k$ .



## Bucle.

Paso 3. Sea  $\sigma \in (0, 1)$ . Si  $\|D_k J_k^- r_k\| \leq (1 + \sigma)\Delta_k$ , asignar  $\lambda_k = 0$  y  $p_k = -J_k^- r_k$ . En otro caso, encontrar  $\lambda_k$  tal que si

$$\begin{bmatrix} J_k \\ \lambda_k^{\frac{1}{2}} D_k \end{bmatrix} p_k \cong - \begin{bmatrix} r_k \\ 0 \end{bmatrix},$$

entonces  $(1 - \sigma)\Delta_k \leq \|D_k p_k\| \leq (1 + \sigma)\Delta_k$ .

```
1 % parametro levenberg-marquardt
2 [pk, lambdak] = pkfun(Delta, Jk, Dk, funk,
    Jm, Q, Pi, n, m, lambdak, maxit2);
```

## Bucle.

```
1 function [pk, lambdak] = pkfun(Delta, Jk, Dk
    , funk, Jm, Q, Pi, n, m, lambdak, maxit)
2
3 phi = @(a) norm(Dk*inv(Jk'*Jk+a.*(Dk'*Dk))*
    Jk'*funk) - Delta;
4 if phi(0) == 0
5     lambdak = 0;
6     pk = -Jm*funk;
7     pk = pk';
8 else
9     lambdak = hebden(phi, Delta, Jk, Dk,
        funk, Q, Pi, n, m, lambdak, maxit);
10    pk = pk2(funk, Q, Pi, Jk, Dk, lambdak, n
        , m);
11 end
```

# Bucle.

Paso 4. Determinar la relación  $\rho_k$  entre reducción real y la esperada.

# Bucle.

Paso 4. Determinar la relación  $\rho_k$  entre reducción real y la esperada.

```
1 rho = rhofun(funk , pk , lambdak , Dk , Jk , fun , xk );
```

# Bucle.

Paso 4. Determinar la relación  $\rho_k$  entre reducción real y la esperada.

```
1 rho = rhofun(funk ,pk ,lambdak ,Dk ,Jk ,fun , xk);
```

```
1 function rho = rhofun(funk ,pk ,lambdak ,Dk ,Jk ,  
    fun ,xk)  
2 funplus = fun(xk+pk);  
3  
4 rhonum=1-(norm(funplus)/norm(funk))^2;  
5 rhoden=(norm(Jk*pk')/norm(funk))^2+2*(sqrt(  
    lambdak)*norm(Dk*pk')/norm(funk))^2;  
6 rho = rhonum/rhoden;
```

## Bucle.

Paso 5. Si  $\rho_k \leq 0,0001$ , asignar  $x_{k+1} = x_k$  y  $J_{k+1} = J_k$ .  
Si  $\rho_k > 0,0001$ , asignar  $x_{k+1} = x_k + p_k$  y calcular  $J_{k+1} = J(x_{k+1})$ .

## Bucle.

Paso 5. Si  $\rho_k \leq 0,0001$ , asignar  $x_{k+1} = x_k$  y  $J_{k+1} = J_k$ .  
Si  $\rho_k > 0,0001$ , asignar  $x_{k+1} = x_k + p_k$  y calcular  $J_{k+1} = J(x_{k+1})$ .

```
1  if rho <= 0.0001
2      % xk+1 = xk y jk+1=jk
3  else
4      xk = xk+pk;
5      % calculo de Jk, Dk con el nuevo xk
6      funk = fun(xk)';
7      [Jk, Dk, dkm1] = JDk(fun,xk,dkm1);
8      iter=iter+1;
9      test = norm((Jk*inv(Dk))*fun(xk)');
10 end
```

## Bucle.

Paso 6. Si  $\rho_k \leq \frac{1}{4}$ , asignar  $\Delta_{k+1} \in [\frac{1}{10}\Delta_k, \frac{1}{4}\Delta_k]$ .  
Si  $\rho_k \in [\frac{1}{4}, \frac{3}{4}]$  y  $\lambda_k = 0$ , o si  $\rho_k \geq \frac{3}{4}$ , asignar  
 $\Delta_{k+1} = 2 \|D_k p_k\|$ .



## Bucle.

Paso 6. Si  $\rho_k \leq \frac{1}{4}$ , asignar  $\Delta_{k+1} \in [\frac{1}{10}\Delta_k, \frac{1}{4}\Delta_k]$ .  
Si  $\rho_k \in [\frac{1}{4}, \frac{3}{4}]$  y  $\lambda_k = 0$ , o si  $\rho_k \geq \frac{3}{4}$ , asignar  
 $\Delta_{k+1} = 2 \|D_k p_k\|$ .

```
1 % actualizacion de Delta
2 if rho <= 0.25
3     Delta = Delta/2;
4 elseif rho >= 0.75
5     Delta = 2*norm(Dk*pk');
6 elseif lambdak == 0
7     Delta = 2*norm(Dk*pk');
8 end
```

Bucle.

Paso 7. Actualizar  $D_k$  y volver al Paso 2.

# Bucle.

Paso 7. Actualizar  $D_k$  y volver al Paso 2.

```
1     end  
2  xk = real(xk);
```

Resolución numérica del problema no lineal de mínimos cuadrados.  
Aplicaciones a las estimación de parámetros de modelos  
matemáticos.

Dídac Blanco Morros.